

# Project 1: CNN 모델 개선을 통한 이미지 분류 성능 향상

이름: 박원일

## 1. 목표

CNN 기반 이미지 분류 모델의 구조와 하이퍼파라미터를 개선하여 분류 성능을 향상시키는 것 이다.

포함 내용:

데이터셋: CIFAR-10

평가 기준: Test Accuracy, Training Loss

## 2. 개선 전략 및 적용 항목

### A. 모델 구조 개선

- i. Conv 레이어 추가하기
- ii. FC 레이어 확장
- iii. 활성화 함수 변경 ReLu > LeakyRelu > ELU

### B. Regularization

- i. L2 정규화 추가
- ii. Dropout 0.3 0.5 0.7 비율 실험

### E. Optimizer 변경

- i. SGD -> Adam 으로 변경
- ii. 학습률 lr 0.01 -> lr 0.001 로 변경

### F. 데이터 증강

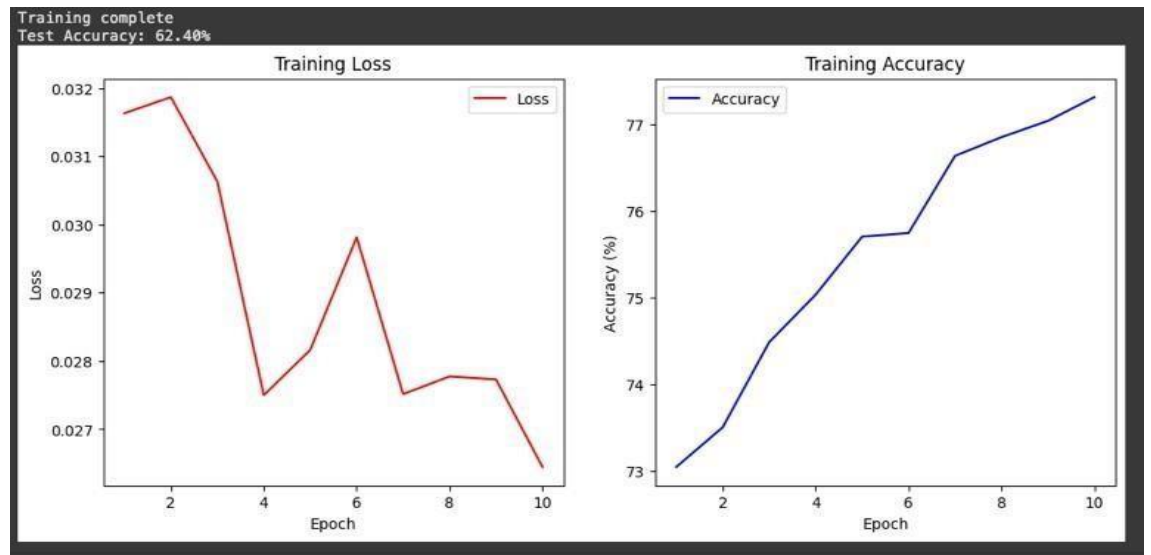
- i. RandomCrop, RandomHorizontalFlip 적용

## 3. 실험결과 요약

실험내용	변경 사항	성능 영향
------	-------	-------

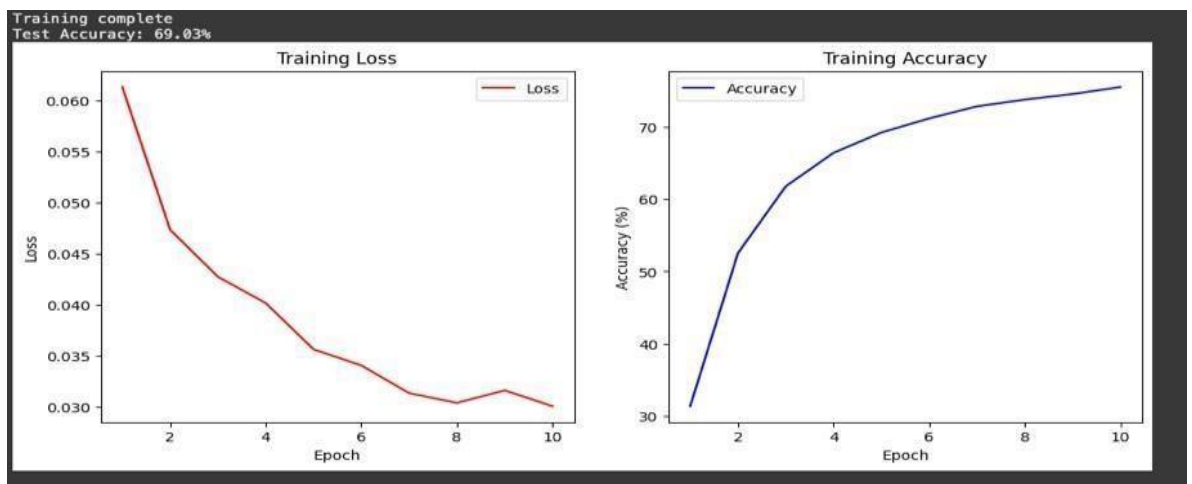
Conv 레이어 추가	3 개의 Conv 로 변경	정확도 상승
FC 레이어 확장	FC1, FC2 층 추가	복잡한 패턴 학습 가능
활성화 함수 변경	ReLU -> LeakyReLU	안정성 증가
Dropout 삽입	0.3 0.5 0.7 실험	0.3 에서 최고 성능 확인

#### 4. 분석



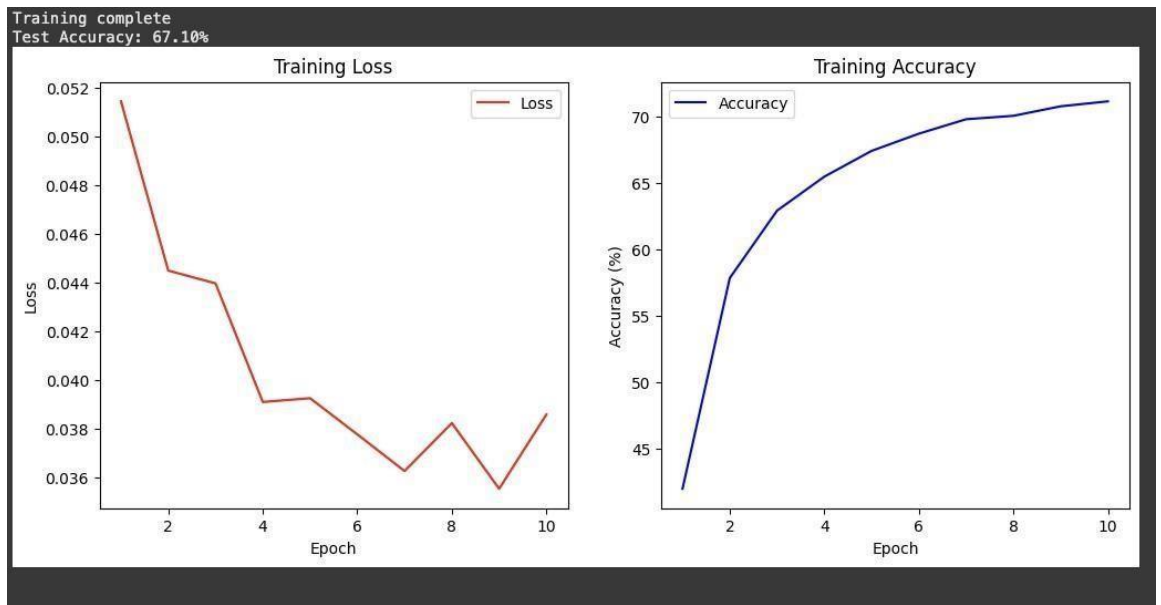
최초 코드 변경전 훈련정확도 대비 테스트 정확도 차이가 큼

#### ⑦ 과적합 발생



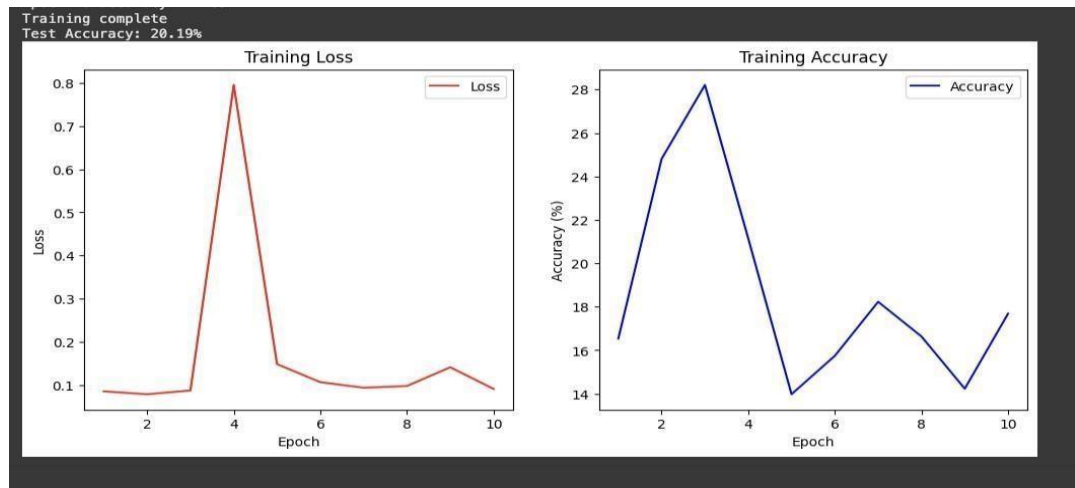
Conv3 Layer 추가, FC 확장, RELU > LeakyReLU 적용 후 (정확도 7%p 상승)

훈련, 테스트 정확도 차이 적음 ⑦ 적절하게 학습됨



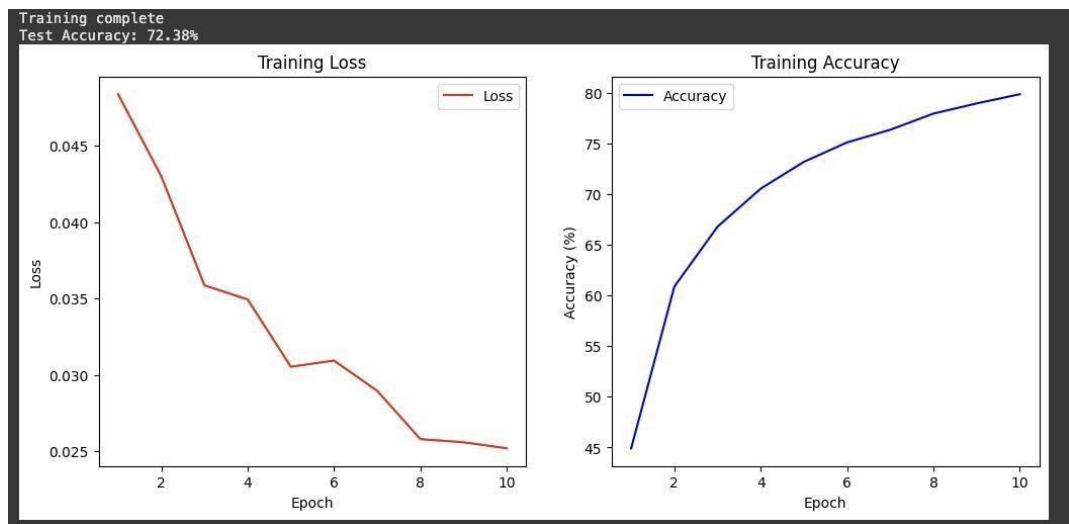
정확도 향상을 위해 LeakyReLU → ELU 로 활성화 함수 변경을 시도하였다.

그러나 ELU 사용 시 오히려 2%p 정확도 감소가 발생하여 다시 LeakyReLU 로 회귀하였다.




Optimizer SGD->Adam 적용 -> 심각한 Underfitting(과소적합) (학습률 0.01) 정확도 20.19%


모델의 Train/Test 정확도가 모두 30% 미만으로 학습 데이터조차 제대로 학습하지 못한 심각한 Underfitting(과소적합) 상태가 관찰되었다. 이는 최적화 전략 문제일 가능성이 있으며, 이를 개선하기 위해 우선적으로는 SGD 로 회귀가 아닌 학습률 조정을 시도할 예정이다.



학습률을 0.01 에서 0.001 로 낮추어 Training 을 해보니 손실 안정화 및 정확도 50%p 개선을 이끌었다.  
과소적합의 원인은 너무 높은 학습률로 인한 불안정한 weight 업데이트로 판단되었다.

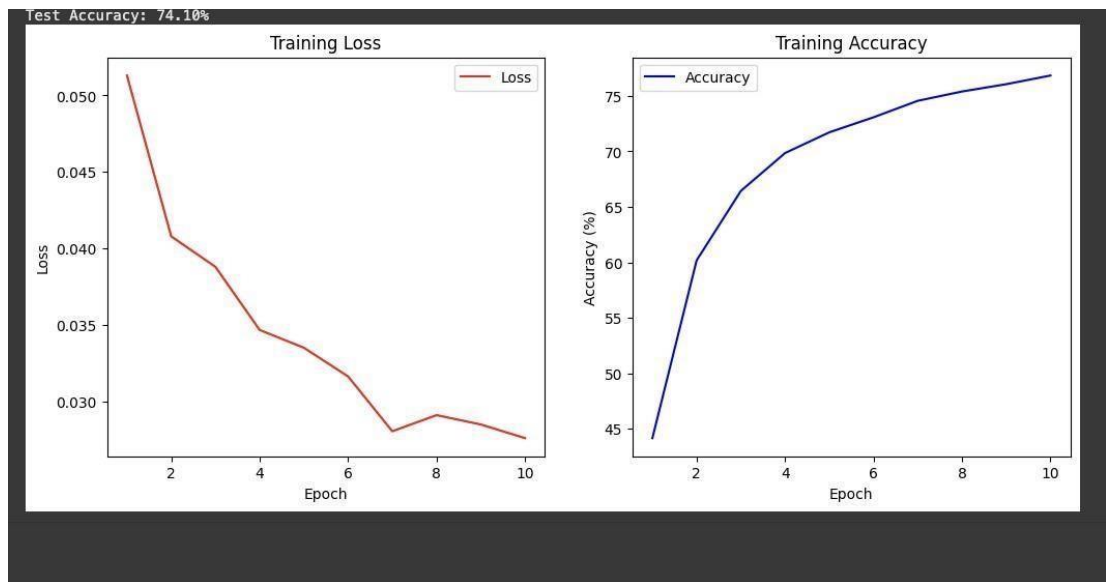


Adam > RMSprop 로 변경 후 2%p 하락이 된 걸 확인하고 다시 Adam 으로 변경하였다.



추후의 overfitting(과적합)을 방지하기 위해 L2 정규화 기법 적용

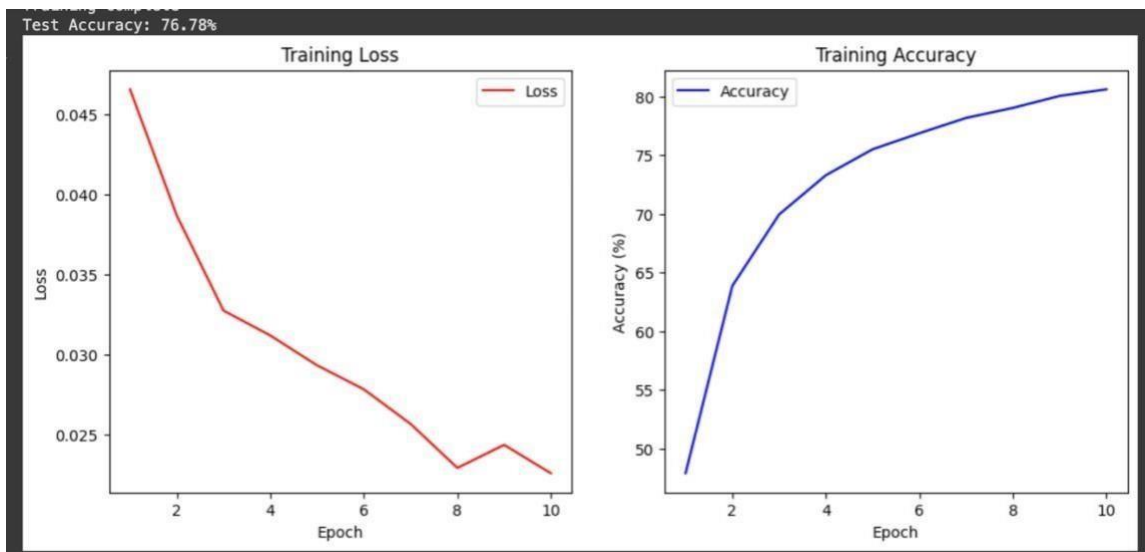
Test Accuracy 엔 딱히 큰 변화는 없었다



### HorizontalFlip 적용상태

초기 코드에서 RandomCrop 이 모델 성능에 부정적인 영향을 준 것으로 나타나, 데이터 증강 기법을 HorizontalFlip 만으로 조정하였다.

이는 원본 이미지의 주요 정보 손실을 줄이면서도 데이터 다양성을 확보해 테스트 정확도 향상 및 학습 안정성 향상에 기여하였다.



모델의 과적합 방지를 위해 Dropout 비율을 0.3, 0.5, 0.7 로 조정하여 실험하였다. 일반적으로 0.5 가 가장 안정적인 설정으로 알려져 있지만, 본 실험에서는 **예상과 다르게 0.3 에서 가장 높은 테스트 정확도(76.78%)**를 기록하였다.

이는 현재 모델 구조와 학습 환경에서 **과도한 정규화(Dropout 0.5 이상)**가 오히려 표현력을 저해한 결과로 해석된다.

따라서, 본 모델에서는 Dropout 0.3 이 최적의 성능을 보이는 설정으로 판단된다.

## 5. 결론

본 프로젝트에서는 모델 구조 변경, 최적화 전략 수정, 정규화 및 데이터 증강을 단계적으로 적용하며 실험을 수행하였다. 각 요소가 모델 성능에 미치는 영향을 수치적, 시각적으로 확인하였으며, 학습률이 성능에 큰 영향을 주며, 학습률은 0.001 에서 가장 높은 정확도 기록했다.

최종적으로 Adam 옵티마이저, Dropout(0.3), Horizontal Flip-only 데이터 증강 조합이 가장 안정적인 수렴과 최고 테스트 정확도인 76.78% 를 기록하였다.